# HW1 Report 311553030 林亮丞

## 1. Introduction

在這次作業中,目標是使用 numpy 實作一個有 2 層 hidden layer 的 network,每層 hidden layer 包含了一層 linear 和一層 sigmoid,並使用 backpropagation 去訓練。而訓練的資料有 2 種,每種 data 有 2 個 feature(x 和 y),x 代表的是 2 維座標,y 代表的是 label,為 0 或 1。 其中一種 data 為 100 個隨機點組成,我稱其為 data\_100,另一種 data 為 X 形分布的,稱其 為 data\_X 。

在這份報告中我會用截圖展示部分實作的程式,以及展示 2 種 data 各自 ground truth 畫出來的圖與各自去訓練的 model 預測出來的圖,並討論使用不同 Ir、hidden\_dim,以及是否使用 sigmoid 的差異。

## 2. Experiment setups:

# A. Sigmoid functions

```
def sigmoid(self, x):
    return 1 / (1 + np.exp(-x))

def derivative_sigmoid(self, x):
    return self.sigmoid(x) * (1 - self.sigmoid(x))
```

## B. Neural network

使用一個有 2 層 hidden layer 的 network,hidden layer 為一層 hidden dim=10 的 linear 和一層 sigmoid,loss 使用 MSE/2,除 2 是為了方便 backward 時微分去掉\*2,經過 backpropagation 去得到各層的 delta 來 update weights

```
class MyNet:

def __init__(self):
    self.epoch = []
    self.train_loss = []
    input_dim = 2
    hidden_dim = 10
    output_dim = 1

# 隨機初始化權重和偏差
    self.W1 = np.random.randn(input_dim, hidden_dim)
    self.b1 = np.random.randn(hidden_dim)
    self.W2 = np.random.randn(hidden_dim, hidden_dim)
    self.b2 = np.random.randn(hidden_dim)
    self.W3 = np.random.randn(hidden_dim, output_dim)
    self.W3 = np.random.randn(hidden_dim, output_dim)
    self.b3 = np.random.randn(output_dim)
```

```
def loss(self, y_true, y_pred):
   loss = np.mean((y_true - y_pred)**2) / 2
   return loss
```

## C. Backpropagation

過程為先 forward 得到各層的結果,再透過 backward 計算各層的 delta,再由這些

delta 與前面 forward 得到的各層結果去計算出每層 weight 要更新的 gradient。

```
# forward
# 第一層隱藏層
Z1 = np.dot(X, self.W1) + self.b1
a1 = self.sigmoid(z1)
# 第二層隱藏層
Z2 = np.dot(a1, self.W2) + self.b2
a2 = self.sigmoid(z2)
# 輸出層
Z3 = np.dot(a2, self.W3) + self.b3
y_pred = self.sigmoid(z3)
train_loss = self.loss(y, y_pred)
```

```
# backward
out_layer_error = y_pred-y
out_layer_delta = out_layer_error * self.derivative_sigmoid(z3)
hidden_layer2_error = np.dot(out_layer_delta, self.W3.T)
hidden_layer2_delta = hidden_layer2_error * self.derivative_sigmoid(z2)
hidden_layer1_error = np.dot(hidden_layer2_delta, self.W2.T)
hidden_layer1_delta = hidden_layer1_error * self.derivative_sigmoid(z1)
```

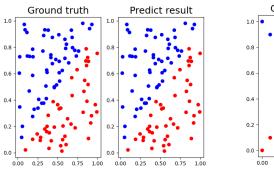
```
# update weights
N = X.shape[0]
self.W3 -= lr * (np.dot(a2.T, out_layer_delta) / N)
self.b3 -= lr * (np.sum(out_layer_delta, axis=0) / N)
self.W2 -= lr * (np.dot(a1.T, hidden_layer2_delta) / N)
self.b2 -= lr * (np.sum(hidden_layer2_delta, axis=0) / N)
self.W1 -= lr * (np.dot(X.T, hidden_layer1_delta) / N)
self.b1 -= lr * (np.sum(hidden_layer1_delta, axis=0) / N)
```

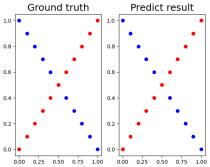
# 3. Results of your testing:

A. Screenshot and comparison figure

Data\_100

Data\_X





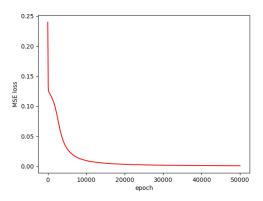
B. Show the accuracy of your prediction

Data\_100: accuracy: 100/100

Data X: accuracy: 21/21

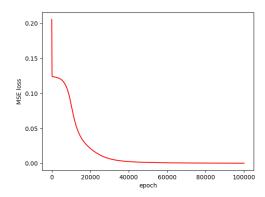
C. Learning curve (loss, epoch curve)

Data 100: lr: 0.1, epochs: 50000



```
epoch 5000, train_loss: 0.029797329203481594
epoch 10000, train_loss: 0.009651602404142057
epoch 15000, train_loss: 0.0051656513067742825
epoch 20000, train_loss: 0.003404366981752707
epoch 25000, train_loss: 0.002492604045534351
epoch 30000, train_loss: 0.0019417826321992283
epoch 35000, train_loss: 0.0015755817533634475
epoch 40000, train_loss: 0.0013158888250258778
epoch 45000, train_loss: 0.0011229831754690895
epoch 50000, train_loss: 0.0009745900760822118
```

Data\_X: lr: 0.1, epochs: 100000



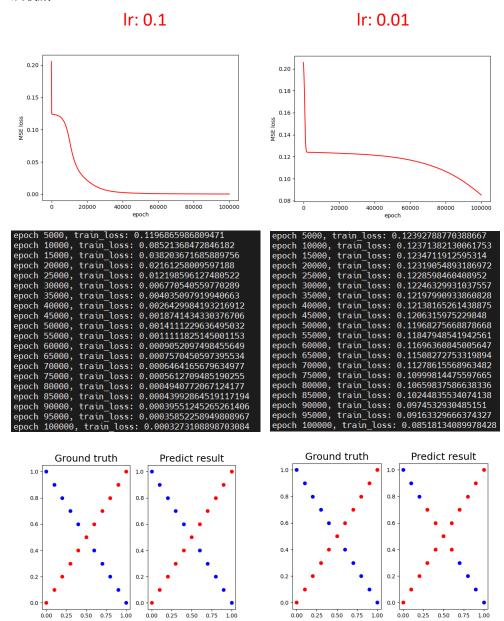
```
epoch 5000, train_loss: 0.1196865986809471
epoch 10000, train_loss: 0.08521368472846182
epoch 15000, train_loss: 0.038203671685889756
epoch 20000, train_loss: 0.02161258009597188
epoch 25000, train_loss: 0.012198596127480522
epoch 30000, train_loss: 0.006770540559770289
epoch 35000, train_loss: 0.004035097919940663
epoch 40000, train_loss: 0.0026429984193216912
epoch 45000, train_loss: 0.0018741434330376706
epoch 50000, train_loss: 0.0014111229636495032
epoch 55000, train_loss: 0.0011111825145001153
epoch 60000, train_loss: 0.00097570450597395534
epoch 70000, train_loss: 0.0006464165679634977
epoch 75000, train_loss: 0.0006464165679634977
epoch 80000, train_loss: 0.0004940772067124177
epoch 85000, train_loss: 0.00043992864519117194
epoch 90000, train_loss: 0.00035852258949808967
epoch 100000, train_loss: 0.0003273108898703084
```

#### 4. Discussion:

以下嘗試都使用 Data\_X 訓練

# A. Try different learning rates:

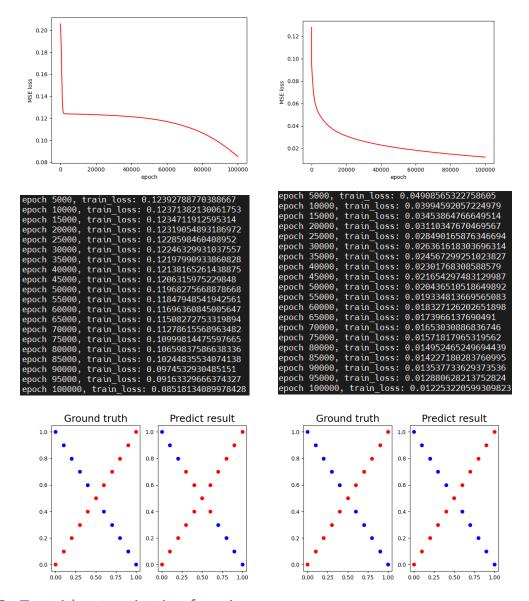
從以下結果可以明顯看出在使用同樣的 epoch 下,當使用較小的 lr 時更新參數的速度 會較緩慢,會需要更多 epoch 才能收斂,而較大的 lr 會更新較快,但也可能會導致無 法收斂。



## B. Try different numbers of hidden units

從以下結果可以看出在 hidden dim 為 10 的情況下,Ir: 0.01 還沒到收斂的地步,但將 hidden dim 設為 100 時則接近收斂,且訓練結果也變完全正確,雖然使用較大 hidden dim 可以使精確度上升,但缺點是訓練時間會變長,因為一個 epoch 需要花更多時間。

lr: 0.01, hidden dim: 10 lr: 0.01, hidden dim: 100



## C. Try without activation functions

如果 network 不使用 activation functions 的話,會只能計算到線性的關係,且容易會使計算 loss 過程產生 overflow,以下為 lr 為 0.1, hidden\_dim=10 情况下不使用任何 activation function 的結果。